НИЯУ “МИФИ”

НИРС

по теме: “Классификация медицинских текстов на наличие побочных эффектов при помощи методов машинного обучения”

Группа: М19-117
Студент: Кайгородов Александр
Преподаватели: Сбоев А.Г. , Рыбка Р.Б.

Москва, 2020

Введение

Тематика представленных наборов твитов склоняется к написанию отзыва о каком-либо медицинском препарате, побочные эффекты которого нужно занести в базу данных для фармакологических служб. Правильное извлечение огромного числа выявленных побочных эффектов может значительно улучшить разработку новых лекарств, но проблема заключается в работе со сложной структурой информации представленной в виде естественного языка.

Для решения данной задачи можно прибегать к использованию машинного обучения, в частности нейронных сетей. Использование классических базовых методов МЛ допустимо, но использование глубинного обучения представляется наиболее приоритетным в данном случае, т.к позволяет получать большую точность при предсказании.

Данная научно-исследовательская работа посвящена исследованию методов машинного обучения с сравнением эффективности работы как классических методов так и методов с использованием нейронных сетей для решения задач классификации текстов.

Для исследования методов поставлены следующие цели:

1. Добыть данные и провести их предобработку
2. Построить модели нейросетевых и классических подходов машинного обучения
3. Обучить модели
4. Получить точности работы моделей
5. Сравнить полученные точности и обозначить наилучшие модели

В качестве данных для исследования были взяты материалы открытого соревнования проводимого Пенсильванским медицинским институтом.

О соревновании
“*Social Media Mining for Health Applications (#SMM4H) Shared Task 2020”*

Задания данного соревнования включают в себя задачи тематики NLP, распространяющиеся на практические цели из сферы здравоохранения. Общая суть указанных заданий данного соревнования окружена вопросами извлечения информации из больших наборов твитов, написанных пользователями в сети.

Основная группа задач данного соревнования сводится к следующим пунктам.
1. Классификация твита на наличие или отсутствие побочного эффекта (ADR)
2. Выделение спана для конкретного побочного эффекта
3. Нормализация побочного эффекта (строгое формулирование)
4. Соотнесение полученного ADR с идентификатором базы данных MedDRA.

В данной работе для исследования выбрана задача из программы соревнования 2020 года:
(названия и описания тасков оставляются в оригинальном виде)

- Task 2: Automatic classification of multilingual tweets that report adverse effects
    - Training data: 20,216 tweets (1,903 “positive” tweets; 18,641 “negative” tweets)
- Task 3: Automatic extraction and normalization of adverse effects in English tweets
    - 1,812 tweets (1,464 “positive” tweets; 778 “negative” tweets)

Оригинальная ссылка на соревнование: #SMM4H Shared Task 2020 (https://healthlanguageprocessing.org/smm4h-sharedtask-2020/)

Данные для решения задачи

Данные, предоставленные организаторами соревнований, содержат посты пользователей твиттера - “твиты”, и выделены в два различных датасета для каждой задачи.

Датасет для task2 содержит N твитов и разметку твитов по классам:

- Есть побочный эффект действия препарата (ADR) указанного в твите
- Побочный эффект действия препарата отсутствует

Датасет для task3 содержит информацию о локальном присутствии ADR в приложенном твите. Используется термин SPAN, которые подразумевает границы написанного ADR-а в виде информации об индексе символов начала и конца описанного эффекта. Также в датасете для task3 присутствуют твиты не имеющие ADR.

Пример твита из датасета для task2:
@fibby1123 are you on paxil .. i need help - ADR отсутствует

@flatchests it has nothing to do with any of that~ apparently seroquel makes you gain alot of weight - ADR присутствует

Пример твита из третьего датасета для task3:
dis lady has the worst cough i wish i had a lozenge - ADR отсутствует

@luckystubbs reppin zoloft&seroquel since last november. i'm hella gainin weight too awesome i'm fat and can't cum i own - ADR присутствует (fat), спан = [101, 104]

Факт дисбаланса данных является очень важным при обучении модели. Проблема существует и в одном из действительных датасетов.

Анализ баланса классов для датасета task2 показал:

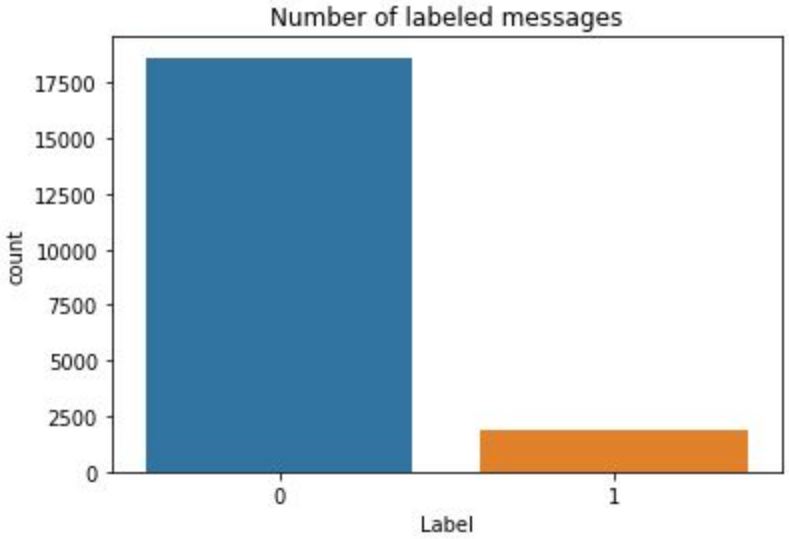

Во датасете task3 присутствует дисбаланс (довольно выраженный) в сторону меток об отсутствии adr в твите. Этот факт важно это учитывается при оценке модели.

Анализ баланса классов для датасета task3 показал:

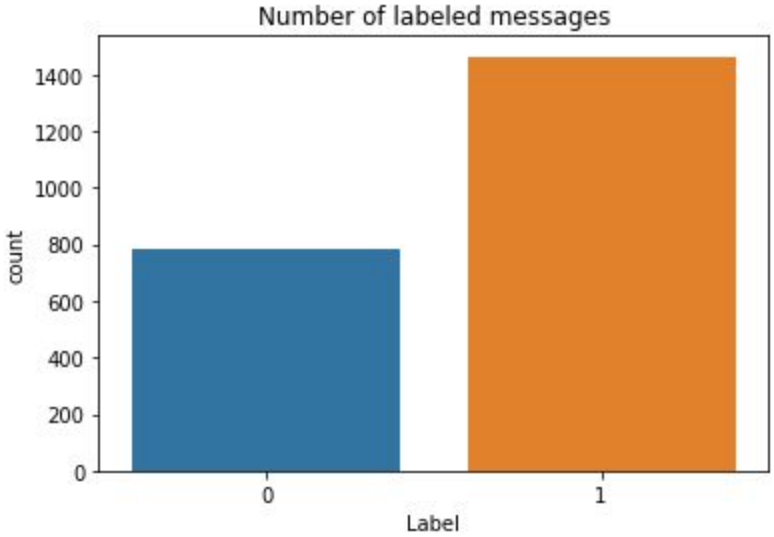

Проведем анализ этих датасетов относительно друг друга. При сравнении используется диаграмма Венна между тренировочными примерами данных task2 и task3.

```
Size of d1:      20216
Size of d2:      1812
Not in d2:       19265
Not in d1:       861
Intercept:       951
```

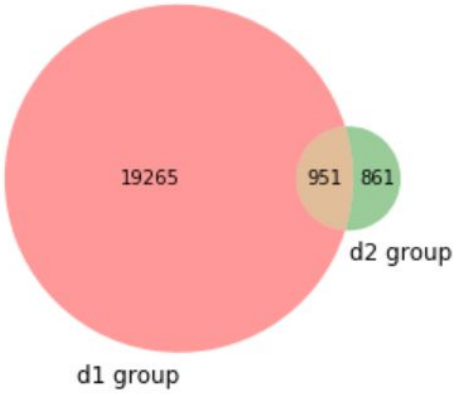

В итоге имеется следующее распределение:

Dataset	ADR	No ADR
Dataset task_2	1903	18641
Dataset task_3	1464	778

Опыт решения задач

Организаторы предоставили ссылку на сборник статей с воркшопа предыдущего года, на котором можно легко ознакомиться с работами других участников. Задания остались в той же тематике, но слегка изменили свои формулировки и все подходы и методы, описанные там не распространяются на текущее соревнование. Тем не мене, работы опубликованные в этом сборнике могут оказаться весьма полезными для ознакомления с работающими подходами и при оценке свой модели относительно полученных ранее. Это даст лучшее представление об эффективности проделанной работы.

LINK -> WORKSHOP (https://www.aclweb.org/anthology/W19-32.pdf)

Наибольший интерес представляют подходы победителей соревнований предыдущих лет. Я выбрал работу одного из участников https://www.aclweb.org/anthology/W19-3207.pdf

В работе говорится об эффективности применения классических методов при решении задачи классификации.

В отдельной части работы описывается подход при решении задачи классификации твитов обозначенной как Task 1. В действительности, набор данных схож по составу набора данных для task2.

В качестве используемых методов выбраны:

- SVM (далее будут изложены подробности метода). Для представления слов использован метод представления мешка слов (BOW). Также был применен метод sent2vec для численного представления твитов.
- В качестве главного решения, в работе выдвигается использование классификатора на основе архитектуры BERT которая была получена при помощи архитектуры трансформера и логистической регрессии в качестве классификатора.

Для оценки результатов использования моделей использовались критерии качества: f1-measure (F1), precision (P), recall (R). Полученные результаты оценок представлены в таблице.

В работе приведены следующие оценки качества выполненной модели:

Run name	F1	P	R
KFU NLP, BERT	57.38	69.14	49.04
KFU NLP, SVM	51.64	56.2	47.76
Average scores	50.19	53.51	50.54

Table 1: Text classification results on the Task 1 test set.

Данные оценки взяты в качестве мерки сравнения полученной мной модели. Данные результаты были похожи на схожих данных, но имеющих меньший объем. Следовательно данные значения не подвергаются прямому сравнению, а представляются как “отсечка”.

Материалы

Предварительная обработка текста.

На этапе подготовки твитов для использования в моделях проводилась процедура предобработки данных. В качестве основных подходов при токенизации и векторизации были применены следующие методы:

- TF-IDF
- FastText

TF-IDF (TF — term frequency, IDF — inverse document frequency) статистическая мера, используемая для оценки важности слова в контексте документа, являющегося частью коллекции документов или корпуса. Вес некоторого слова пропорционален частоте употребления этого слова в документе и обратно пропорционален частоте употребления слова во всех документах коллекции.

FastText - библиотека разработанная компанией Facebook для получения эмбеддингов слов. Классификатор FastText библиотеки gensim использует по умолчанию следующие параметры обработки: model: Архитектура CBOW, Skipgram. (CBOW по умолчанию).

По существу, FastText обрабатывает текст там же подходом что и метод word2vec, но его ключевое отличие заключается в том что обработка уже идет на уровне символов. Это дает возможность использовать в качестве векторного представления слова которые ранее не оказывались в словаре.

Иллюстрация скользящего окна word2vec.

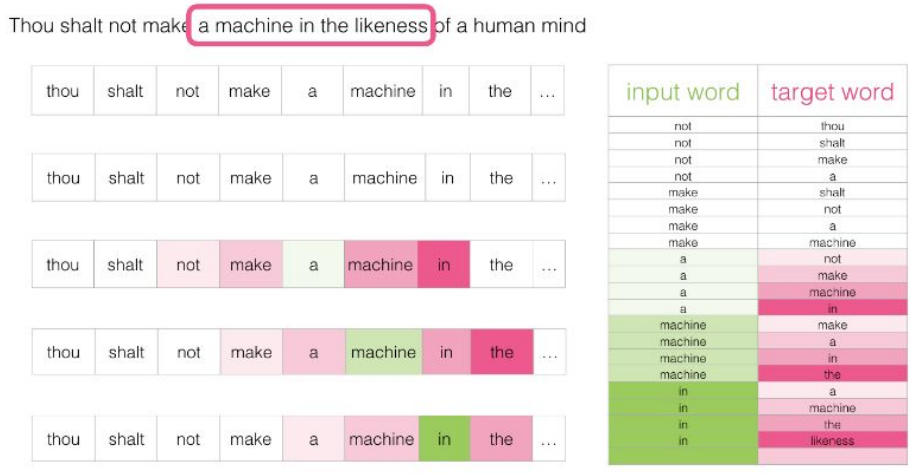

Подходы на базе методов машинного обучения

Метод опорных векторов (SVM, support vector machine) — набор схожих алгоритмов обучения с учителем, использующихся для задач классификации и регрессионного анализа. Принадлежит семейству линейных классификаторов. (https://en.wikipedia.org/wiki/Support_vector_machine)

Многослойный перцептрон (MLP) - это класс искусственных нейронных сетей прямого распространения, состоящих как минимум из трех слоев: входного, скрытого и выходного. За исключением входных, все нейроны используют нелинейную функцию активации. (https://wiki.loginom.ru/articles/multilayered-perceptron.html)

Градиентный бустинг (GBM) — это техника машинного обучения для задач классификации и регрессии, которая строит модель предсказания в форме ансамбля слабых предсказывающих моделей, обычно деревьев решений. (https://neurohive.io/ru/osnovy-data-science/gradientyj-busting/)

TPOT - библиотека осуществляющая самостоятельный поиск подходящей модели с оптимизированными параметрами. Данных подход является очень универсальным и простым для программиста, но требует значительных вычислительных мощностей. Поиск решения осуществлялся для третьего датасета и сравнивался с наилучшей моделью отработавшей на втором датасете. Подробней о TPOT http://epistasislab.github.io/tpot/

Подходы на основе нейронных сетей.

LSTM - это искусственная нейронная сеть, содержащая LSTM-модули вместо или в дополнение к другим сетевым модулям. LSTM-модуль — это рекуррентный модуль сети, способный запоминать значения как на короткие, так и на длинные промежутки времени. Ключом к данной возможности является то, что LSTM-модуль не использует функцию активации внутри своих рекуррентных компонентов. Позволяет выявлять временные зависимости.

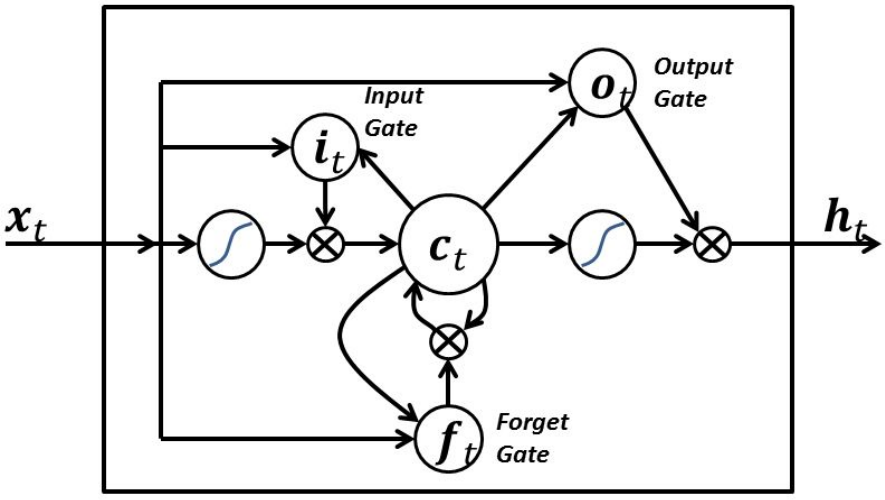

CNN - сверточная нейронная сеть. Свое название получила из-за применения операции свертки. Широко используется в сфере CV где рабочее пространство представлено двухмерными картинками, но также может быть применена в случае одномерной свертки.

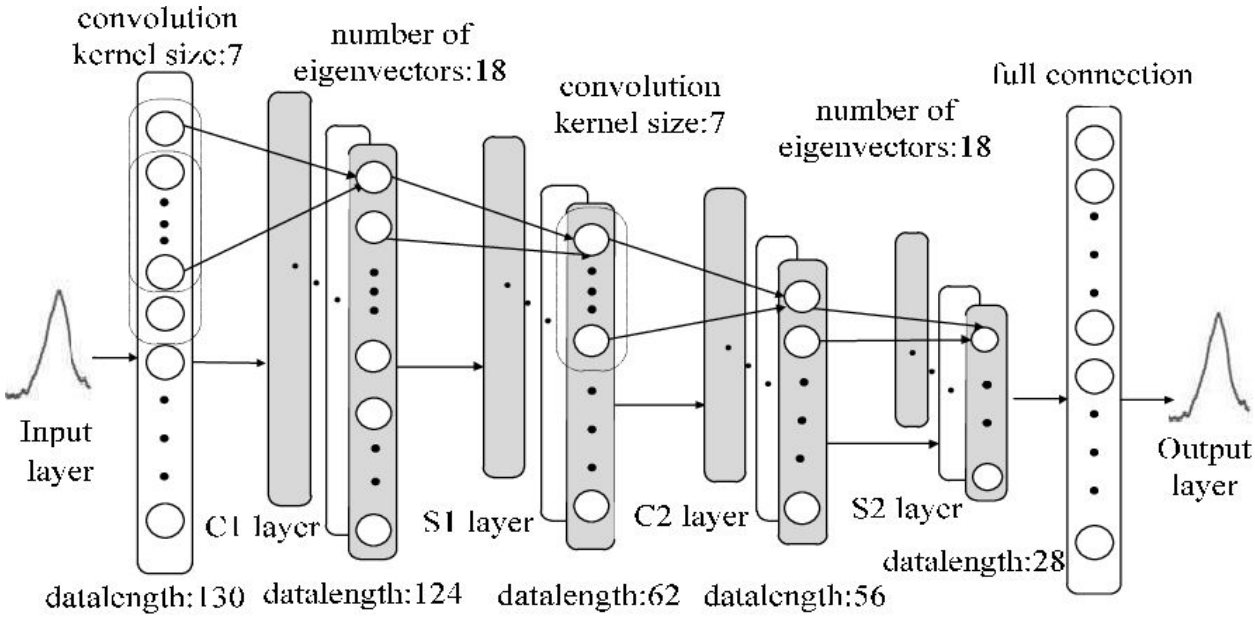

Подробней о технологии можно узнать тут:
https://en.wikipedia.org/wiki/Convolutional_neural_network

Метрика качества

В связи с тем что данные несбалансированные по классам, то оценка моделей по параметру accuracy уже не будет являться объективной. В данном случае, для оценки качества модели применяется материка f1-score (F-мера).

Данная оценка основана на вычислении двух следующих параметров:

- Точность (precision)
- Полнота (recall)

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

В полученной таблице содержится информация сколько раз система приняла верное и сколько раз неверное решение по документам заданного класса. А именно:

- TP - истинно-положительное решение;
- TN — истинно-отрицательное решение;
- FP — ложно-положительное решение;
- FN — ложно-отрицательное решение.

Категория i		Экспертная оценка	
		Положительная	Отрицательная
Оценка системы	Положительная	TP	FP
	Отрицательная	FN	TN

Модели

Классические модели

В качестве изучаемых классических моделей были построены следующие связки:

- TF-IDF + SVM
- TF-IDF + MLP
- TF-IDF + GMB
- FastText + SVM
- TPOT

Обучение описанных моделей проводилось на представленных датасетах. Топология применяемых методов и логика построения решения в целом представлена в приложениях к работе с кодом моделей.

Реализация представленных классических моделей исполнялась при использовании библиотеки scikit-learn.

При исследовании работоспособности классических моделей был применен метод кросс-валидации по фолдам. Данный подход позволяет получить более объективную оценку модели за счет использования имеющихся данных полностью. Полученные оценки моделей при таком подходе лучше отражают ее способность к решению задачи.

Во время исследований, среди используемых с TF-IDF моделей SVM, MLP и GBM было выявлено что в связке TFIDF + SVM лучшее сочетание качества и скорости обучения. Данная модель была применена при обучении на третьем датасете и сравнена с полученным результатом TPOT. Такое решение было принято в связи с слабыми

вычислительными мощностями, которых не хватит для применения TPOT на втором датасете.

В результате исследования получены следующие значения качества используемых моделей.

MODEL	F1 score, %	Std
TFIDF + SVM	64.328	6.011
TFIDF + MLP	65.988	5.821
TFIDF + GBM	57.575	3.853
FastText + SVM	86.925	2.338
TFIDF + SVM (d3)	74.321	-
TFIDF + TPOT (d3)	75.177	-

Выводы: среди проведенных оценок, наилучшей на втором датасете оказалась модель с векторизацией через модуль FastText и моделью SVM, но вычислительная скорость такой модели не оказалась привлекательной, именно поэтому в качестве центральной классической модели мной была выбрана модель опорных векторов (SVM) с предварительной обработкой при помощи подхода TF-IDF.

Модели на основе нейронных сетей

В процессе подготовки текста к работе с сетью был использован набор эмбеддингов “British National Corpus”. Обработка текста происходила в следующем порядке. Токенизация -> формирование матрицы размерностью *Число_твитов* * *Макс_длина_предложения* (наполнение паддингом) -> выравнивае эмбеддинга по количеству участвующих слов в вычислениях

При загрузке в модель, каждое слово будет встречать слой эмбеддинга которые паддингами будем извлекать вектора из представленного эмбеддинга дял каждого слова и использовать в тренировке сети.

Тренировка и оценка моделей проходили на следующих размерах данных.
n_items_for_train = 500
n_items_for_test = 100
max_words = 2000

LSTM

В качестве принятой структуры нейронной сети использовались попытки реализовать два типа сетей, с классическим LSTM и двунаправленным LSTM (BI-LSTM).

- LSTM

```
Model: "sequential_1"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
embedding_1 (Embedding)      (None, 36, 300)           600300
_________________________________________________________________
lstm_2 (LSTM)                (None, 128)               219648
_________________________________________________________________
dense_3 (Dense)              (None, 1)                 129
=================================================================
Total params: 820,077
Trainable params: 219,777
Non-trainable params: 600,300
_________________________________________________________________
None
```

- двунаправленная LSTM

```
Model: "model_1"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
input_1 (InputLayer)         (None, 36)                0
_________________________________________________________________
embedding_1 (Embedding)      (None, 36, 300)           600300
_________________________________________________________________
bidirectional_1 (Bidirection (None, 128)               186880
_________________________________________________________________
dropout_1 (Dropout)          (None, 128)               0
_________________________________________________________________
batch_normalization_1 (Batch (None, 128)               512
_________________________________________________________________
dense_1 (Dense)              (None, 32)                4128
_________________________________________________________________
dropout_2 (Dropout)          (None, 32)                0
_________________________________________________________________
batch_normalization_2 (Batch (None, 32)                128
_________________________________________________________________
dense_2 (Dense)              (None, 1)                 33
=================================================================
Total params: 791,981
Trainable params: 191,361
Non-trainable params: 600,620
_________________________________________________________________
lstm_10_10_0.21_0.18
```

Embedding может находится в состоянии Freez что означает что при тренировке сети, вектора слов изменяться не будут. В противном случае происходит дообучение уже имеющихся векторов представления слов.

В качестве попыток улучшения были применены следующие действия.

- Добавить второй слой эмбеддингов которые уже будет обучаться
- Использовать batch_generator

В первой модификации использовались те-же значения размеров данных Конфигурация модели:

```
Model: "model_1"
__________________________________________________________________________________________________
Layer (type)                    Output Shape         Param #     Connected to
==================================================================================================
input_1 (InputLayer)            (None, 36)           0
__________________________________________________________________________________________________
input_2 (InputLayer)            (None, 36)           0
__________________________________________________________________________________________________
embedding_1 (Embedding)         (None, 36, 300)      1200300     input_1[0][0]
__________________________________________________________________________________________________
embedding_2 (Embedding)         (None, 36, 300)      1200300     input_2[0][0]
__________________________________________________________________________________________________
bidirectional_1 (Bidirectional) (None, 128)          186880      embedding_1[0][0]
                                                                 embedding_2[0][0]
__________________________________________________________________________________________________
concatenate_1 (Concatenate)     (None, 256)          0           bidirectional_1[0][0]
                                                                 bidirectional_1[1][0]
__________________________________________________________________________________________________
dropout_1 (Dropout)             (None, 256)          0           concatenate_1[0][0]
__________________________________________________________________________________________________
batch_normalization_1 (BatchNor (None, 256)          1024        dropout_1[0][0]
__________________________________________________________________________________________________
dense_1 (Dense)                 (None, 32)           8224        batch_normalization_1[0][0]
__________________________________________________________________________________________________
dropout_2 (Dropout)             (None, 32)           0           dense_1[0][0]
__________________________________________________________________________________________________
batch_normalization_2 (BatchNor (None, 32)           128         dropout_2[0][0]
__________________________________________________________________________________________________
dense_2 (Dense)                 (None, 1)            33          batch_normalization_2[0][0]
==================================================================================================
Total params: 2,596,889
Trainable params: 1,396,013
Non-trainable params: 1,200,876
__________________________________________________________________________________________________
lstm_10_10_0.16_0.17
```

В качестве улучшения двунаправленной модели LSTM был применен метод тренировки с использованием батч-генератора. Для этого создан отдельный класс генератора данных для тренировки и реализован через метод библиотеки keras fit_generator. Код модели и класса генератора в приложении.

CNN

В качестве реализации сверточной сети были опробованы два подхода.

- Сверточная сеть работающая на уровне символов
- Сверточная сеть работающая на уровне слов

При предобработке данных для сверточной сети на уровне символов была использована простейшая прямая токенизация по символам всех твитов предварительно обработанных и представленных через лемматизатор который был применен для LSTM.

Топология сверточной сети для уровня символов:

```
Model: "model_1"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
input (InputLayer)           (None, 200)               0
_________________________________________________________________
embedding_1 (Embedding)      (None, 200, 69)           4830
_________________________________________________________________
conv1d_1 (Conv1D)            (None, 194, 256)          123904
_________________________________________________________________
activation_1 (Activation)    (None, 194, 256)          0
_________________________________________________________________
max_pooling1d_1 (MaxPooling1 (None, 64, 256)           0
_________________________________________________________________
conv1d_2 (Conv1D)            (None, 58, 256)           459008
_________________________________________________________________
activation_2 (Activation)    (None, 58, 256)           0
_________________________________________________________________
max_pooling1d_2 (MaxPooling1 (None, 19, 256)           0
_________________________________________________________________
conv1d_3 (Conv1D)            (None, 13, 256)           459008
_________________________________________________________________
activation_3 (Activation)    (None, 13, 256)           0
_________________________________________________________________
conv1d_4 (Conv1D)            (None, 7, 256)            459008
_________________________________________________________________
activation_4 (Activation)    (None, 7, 256)            0
_________________________________________________________________
max_pooling1d_3 (MaxPooling1 (None, 2, 256)            0
_________________________________________________________________
flatten_1 (Flatten)          (None, 512)               0
_________________________________________________________________
dense_1 (Dense)              (None, 200)               102600
_________________________________________________________________
dropout_1 (Dropout)          (None, 200)               0
_________________________________________________________________
dense_2 (Dense)              (None, 200)               40200
_________________________________________________________________
dropout_2 (Dropout)          (None, 200)               0
_________________________________________________________________
dense_3 (Dense)              (None, 2)                 402
=================================================================
Total params: 1,648,960
Trainable params: 1,648,960
Non-trainable params: 0
```

Сверточная нейронная сеть на уровне слов использует ту же самую логику что и сверточная сеть на уровне символов, только на этот раз токенизация происходит на уровне слов по тому же самому обработанному набору.

Топология сверточной сети для уровня слов.

```
Model: "model_2"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
input_3 (InputLayer)         (None, 36)                0
_________________________________________________________________
embedding_3 (Embedding)      (None, 36, 300)           1200300
_________________________________________________________________
conv1d_7 (Conv1D)            (None, 34, 300)           270300
_________________________________________________________________
dropout_8 (Dropout)          (None, 34, 300)           0
_________________________________________________________________
max_pooling1d_7 (MaxPooling1 (None, 17, 300)           0
_________________________________________________________________
conv1d_8 (Conv1D)            (None, 13, 300)           450300
_________________________________________________________________
dropout_9 (Dropout)          (None, 13, 300)           0
_________________________________________________________________
max_pooling1d_8 (MaxPooling1 (None, 6, 300)            0
_________________________________________________________________
conv1d_9 (Conv1D)            (None, 2, 300)            450300
_________________________________________________________________
dropout_10 (Dropout)         (None, 2, 300)            0
_________________________________________________________________
max_pooling1d_9 (MaxPooling1 (None, 2, 300)            0
_________________________________________________________________
flatten_3 (Flatten)          (None, 600)               0
_________________________________________________________________
dropout_11 (Dropout)         (None, 600)               0
_________________________________________________________________
batch_normalization_2 (Batch (None, 600)               2400
_________________________________________________________________
dense_1 (Dense)              (None, 32)                19232
_________________________________________________________________
dropout_12 (Dropout)         (None, 32)                0
_________________________________________________________________
batch_normalization_3 (Batch (None, 32)                128
_________________________________________________________________
dense_2 (Dense)              (None, 1)                 33
=================================================================
Total params: 2,392,993
Trainable params: 1,191,429
Non-trainable params: 1,201,564
_________________________________________________________________
CNN
```

LSTM+CNN

Совместное применение сверточной нейронной сети и сети LSTM. Предобработка данных осуществлялась аналогичным образом как и в предыдущих двух подпунктах.

Топология сети:

```
Model: "model_1"
```

Layer (type)	Output Shape	Param #	Connected to
input_CHARS (InputLayer)	(None, 200)	0	
embedding_3 (Embedding)	(None, 200, 69)	4830	input_CHARS[0][0]
conv1d_1 (Conv1D)	(None, 194, 256)	123904	embedding_3[0][0]
activation_1 (Activation)	(None, 194, 256)	0	conv1d_1[0][0]
max_pooling1d_1 (MaxPooling1D)	(None, 64, 256)	0	activation_1[0][0]
conv1d_2 (Conv1D)	(None, 58, 256)	459008	max_pooling1d_1[0][0]
activation_2 (Activation)	(None, 58, 256)	0	conv1d_2[0][0]
max_pooling1d_2 (MaxPooling1D)	(None, 19, 256)	0	activation_2[0][0]
conv1d_3 (Conv1D)	(None, 13, 256)	459008	max_pooling1d_2[0][0]
activation_3 (Activation)	(None, 13, 256)	0	conv1d_3[0][0]
conv1d_4 (Conv1D)	(None, 7, 256)	459008	activation_3[0][0]
activation_4 (Activation)	(None, 7, 256)	0	conv1d_4[0][0]
max_pooling1d_3 (MaxPooling1D)	(None, 2, 256)	0	activation_4[0][0]
flatten_1 (Flatten)	(None, 512)	0	max_pooling1d_3[0][0]
dense_1 (Dense)	(None, 200)	102600	flatten_1[0][0]
input_1 (InputLayer)	(None, 36)	0	
input_2 (InputLayer)	(None, 36)	0	
dropout_1 (Dropout)	(None, 200)	0	dense_1[0][0]
embedding_1 (Embedding)	(None, 36, 300)	600300	input_1[0][0]
embedding_2 (Embedding)	(None, 36, 300)	600300	input_2[0][0]
dense_2 (Dense)	(None, 200)	40200	dropout_1[0][0]
bidirectional_1 (Bidirectional)	(None, 128)	186880	embedding_1[0][0] embedding_2[0][0]
dropout_2 (Dropout)	(None, 200)	0	dense_2[0][0]
concatenate_1 (Concatenate)	(None, 456)	0	bidirectional_1[0][0] bidirectional_1[1][0] dropout_2[0][0]
dropout_3 (Dropout)	(None, 456)	0	concatenate_1[0][0]
batch_normalization_1 (BatchNor	(None, 456)	1824	dropout_3[0][0]
dense_3 (Dense)	(None, 32)	14624	batch_normalization_1[0][0]
dropout_4 (Dropout)	(None, 32)	0	dense_3[0][0]
batch_normalization_2 (BatchNor	(None, 32)	128	dropout_4[0][0]
dense_4 (Dense)	(None, 1)	33	batch_normalization_2[0][0]

```
Total params: 3,052,647
Trainable params: 2,451,371
Non-trainable params: 601,276
```

Результаты

В отличии от таблицы результатов представленной для результатов работы с классическими моделями, в данной таблице отсутствует показатель СКО для оценки, т.к использование кросс-валидации по фолдам представляется очень затратной. Взамен представлены значения матриц сопряженности получаемых результатов (confusion matrix).

Для сравнения показания классической модели был взят результат работы TF-IDF на том же самом, но уже урезанном наборе данных датасет task2. Качество такой модели получилась ожидаемо меньше чем на полном наборе и теперь равняется 0.48.

Данная матрица описана в пункте “Метрика качества” и продемонстрирована в конце.

LSTM or CNN	**F1-score**	**Confusion matrix**
LSTM Embedding (freez=True)	0.73	114/32 49/105
LSTM Embedding (freez=False)	0.74	111/39 39/111
LSTM Embedding (freez=False) + Embedding (freez=True)	0.73	116/37 43/104
CNN char_lvl	0.42	72/84 90/54
CNN word_lvl	0.71	100/55 31/114
LSTM + CNN	0.77 (0.79 extended data 1200\400)	99/53 16/132
TF-IDF + SVM	0.48	-

Вывод: наилучший результат получен на модели с совместным использованием LSTM сети и сверточной сети. Данное явление можно описать увеличением емкости модели и как следствие улучшение ее обобщающей способности.

В дальнейшем, при увеличении объема тренировочных и тестировочных данных, мной ожидается увеличение качества предсказаний данной модели которое, вероятно, окажется лучше чем у модели FastText + SVM.

Настройка гиперпараметров в Hyperopt и Hyperas

Получение лучших гиперпараметров используемых в сети определяющих как ее топологию так и свойства слоев в ней является одной из самой важных и трудоемких задач при проектировании сети. Метод определения этих гипер параметров зачастую сводится к простому перебору наиболее вероятных значений которые способны улучшить способность сети к обобщению с наименьшей ошибкой.

Для более комфортного подбора параметров можно использовать вспомогательные библиотеки hyperopt и hyperas. Первая является базой разработки, вторая является модифицированным и упрощенным вариантом первой специально для работы вместе с библиотекой keras.

Данные библиотеки автоматизируют поиск наилучших параметров с контролем качества получаемых сетей. На выходе получаем перечень наиболее подходящих значений которые в дальнейшем следует использовать на полном наборе данных для получения лучшего качества сети.

CNN уровень символов + hyperas

Получены следующие оптимальные параметры

'Dense': 2, 'Dense_1': 2, 'Dropout': 0.6108763092812357, 'Dropout_1': 0.7371698374615214, 'activation': 0, 'activation_1': 0, 'batch_size': 1, 'optimizer': 2	'Dense': hp.choice('Dense', [256, 512, 1024]), 'activation': hp.choice('activation', ['relu', 'sigmoid']), 'Dropout': hp.uniform('Dropout', 0, 1), 'Dense_1': hp.choice('Dense_1', [256, 512, 1024]), 'activation_1': hp.choice('activation_1', ['relu', 'sigmoid']), 'Dropout_1': hp.uniform('Dropout_1', 0, 1), 'Optimizer': hp.choice('optimizer', ['rmsprop', 'adam', 'sgd']), 'Batch_size': hp.choice('batch_size', [32, 64, 128]),

После проверки полученных подстановкой в изначальную модель, точность классификации увеличилась на 2 процента.

CNN уровень символов + hyperopt

Расчет сильно усложнен требуемыми вычислениями, при минимальной обработке получены параметры ценность которых сомнительна, но доказывает стремление к оптимизации

('batch_size', 1) ('dropout1', 0.6334371211063357) ('dropout2', 0.36283182783153534) ('dropout3', 0.6297297987936828) ('dropout4', 0.6357503507027977) ('dropout5', 0.36563410317891387) ('hidden_activation', 2) ('layers', 2) ('loss', 0) ('optimizer', 1) ('pooling_size1', 0) ('pooling_size2', 0) ('pooling_size3', 1) ('pooling_size4', 0) ('pooling_size5', 1)	'choice': hp.choice('layers', [1, 2, 3, 4]), 'pooling_size1': hp.choice('pooling_size1', [3]), 'pooling_size2': hp.choice('pooling_size2', [3, -1]), 'pooling_size3': hp.choice('pooling_size3', [3, -1]), 'pooling_size4': hp.choice('pooling_size4', [3, -1]), 'pooling_size5': hp.choice('pooling_size5', [3, -1]), 'dropout1': hp.uniform('dropout1', .25,.75), 'dropout2': hp.uniform('dropout2', .25,.75), 'dropout3': hp.uniform('dropout3', .25,.75), 'dropout4': hp.uniform('dropout4', .25,.75), 'dropout5': hp.uniform('dropout5', .25,.75), 'batch_size' : hp.choice('batch_size', [32, 64]), 'hidden_activation': hp.choice('hidden_activation', ['relu', 'sigmoid', 'tanh', 'selu']), 'optimizer': hp.choice('optimizer',['adadelta', 'adam', 'rmsprop']), 'loss': hp.choice('loss', ['binary_crossentropy']), 'nb_epochs' : 15, 'activation': 'relu', 'patience': 10

После подстановки, точность модели не изменилась. Для получения изменений стоит применить большее число экспериментов, что требует больше вычислительных мощностей.

LSTM+CNN и hyperopt

Наиболее сложная реализация с вычислительной точки зрения

('batch_size', 1) ('dense_size', 0) ('dropout1', 0.39461651019515437) ('dropout2', 0.7396057604413669) ('dropout3', 0.4408370824285548) ('hidden_activation', 1) ('hidden_activation2', 1) ('loss', 0) ('optimizer', 2) ('pooling_size1', 0) ('pooling_size2', 0)	'pooling_size1': hp.choice('pooling_size1', [3, 5]), 'pooling_size2': hp.choice('pooling_size2', [3, 5]), 'dropout1': hp.uniform('dropout1', .25,.5), 'dropout2': hp.uniform('dropout2', .25,.5), 'dropout3': hp.uniform('dropout3', .25,.5), 'dense_size': hp.choice('dense_size', [32, 64, 128]), 'batch_size' : hp.choice('batch_size', [32, 64]), 'hidden_activation': hp.choice('hidden_activation', ['relu', 'sigmoid', 'tanh', 'selu']), 'hidden_activation2': hp.choice('hidden_activation2', ['relu', 'sigmoid', 'tanh','selu']), 'optimizer': hp.choice('optimizer',['adadelta', 'adam', 'rmsprop']), 'loss': hp.choice('loss', ['binary_crossentropy']), 'epochs' : 15, 'activation': 'relu', 'patience': 5

Точность модели оказалась меньше. Решение может быть найдено увеличением числа экспериментов.

Заключение

По итогам проделанной работы , можно сделать несколько заключений, которые приведены в списке:

- Использование классических методов в задачах классификации текста возможно и имеет свои преимущества в виде более быстрых процессов обучения и детерминированности работы
- Для более качественных результатов рекомендуется применение технологий глубинного обучения
- Для применения глубинного обучения требуется большее количество исходных данных
- Для работы с глубинным обучением разумно использовать графические карты, в ином случае тренировка на обучающих данных может занять весьма продолжительное время
- Возможно совместное применение методов классического м.о. и глубинного.
- Предварительная обработка данных для обучений является крайне важным этапом, при ответственном подходе к которому можно улучшить качество полученного результата и ускорить обучение
- Возможно применение уже предобученных эмбеддингов

Лично для меня оказалось полезным более тесное ознакомление с применяемыми библиотеками, такими как scikit-learn, keras, tensorflow, pandas. Осуществлено практическое ознакомление с функциями и методами библиотек, были предприняты попытки модификации подходов. Изучены методы обработки естественного языка.